AI指标异动聚类分析架构（baseline）

流程回顾

1.人工定义了个各产线异常指标

2.总结影响指标波动的主要维度以及贡献度

3.聚类客人诉求

4.基于用户语义，查看相关场景的进线分布

5.查看明细会话和LLM总结会话内容

其实前四步来处理数据，封装了数据的复杂性，主要聚焦于最后一步

1.数据格式：

2.架构：

原始数据->数据处理->HDBSCAN聚类->汇总结果（按照不同的类别整理数据）->LLM分析原因

->对比两期数据的原因->总结异动原因（就是相比于前期数据新出现的簇类）

3.方法：

1.环境配置：

python库：Pandas，Numpy，Hdbscan，Sklearn，Matplotlib，Seaborn，Openai，Dotenv

2.项目目录：

```
ai指标/
├── .venv/                    # Python虚拟环境
├── data/                     # 数据文件目录
│   ├── clustering_result.csv     # 聚类结果数据
```

```
│   ├── conversation_samples.csv  # 原始样本数据
│   └── cleaned_data.csv          # 预处理后的数据
├── clustering.py                 # 数据聚合脚本
├── cluster_analysis_report.txt   # 分析报告
├── preprocessing.py              # 数据预处理脚本
├── llm_analysis.py               # LLM分析脚本
└── README.md                     # 项目说明文档
```

3.关键模块：

1.clustering.py这里面就是HDBSCAN聚类的是实现

原理讲解：

HDBSCAN（Hierarchical Density-Based Spatial Clustering of Applications with Noise）是一种基于层次密度的聚类算法，其核心思想是"密集的区域是簇，稀疏的区域是噪声"。算法首先计算每个数据点的核心距离（到第k个最近邻居的距离）来衡量局部密度，然后基于核心距离构建互达距离矩阵，使得密集区域的点更容易连接。接着通过最小生成树（MST）找到连接所有点的最短路径网络，再从MST构建层次聚类树，通过逐步剪断长边形成不同粒度的簇划分。最后通过稳定性分析提取在较大距离范围内持续存在的稳定簇，并将无法归入任何稳定簇的点标记为噪声（cluster=-1）。整个过程无需预先指定簇的数量，能够自动发现数据中的自然分组。算法还会为每个点计算聚类概率（表示归属置信度）和异常分数（表示离群程度），提供比传统方法更丰富的聚类质量信息。在实际应用中，关键参数包括min_cluster_size（簇的最小规模）和min_samples（判定密集的邻居数阈值），前者控制簇的粗细粒度，后者影响对密度的敏感度。

相比传统的K-Means算法，HDBSCAN具有显著优势：（1）无需预先指定簇数量，K-Means必须人为设定K值，而HDBSCAN能自动发现数据中的簇；（2）可处理任意形状的簇，K-Means只能识别球形簇，而HDBSCAN能发现椭圆形、条状、不规则形状等复杂簇结构；（3）自动识别噪声点，K-Means强制将所有点分配到某个簇，而HDBSCAN能将离群点标记为噪声（cluster=-1），避免噪声污染簇质量；（4）适应不同密度的簇，K-Means假设所有簇密度相似，而HDBSCAN通过动态密度判定能同时处理密集簇和稀疏簇；（5）提供置信度信息，HDBSCAN输出每个点的聚类概率和异常分数，便于评估结果可靠性，而K-Means只给出硬分配；（6）对初始化不敏感，K-Means依赖随机初始化可能陷入局部最优，而HDBSCAN基于密度的确定性算法结果稳定可复现。因此，对于像客服对话embedding这类簇数量未知、分布不均匀、含噪声数据的场景，HDBSCAN是比K-Means更合适的选择。

其实说白了就是可以自动分组不用提前预设

2.llm_analysis这里面就是用api调用LLM来分析，可以在本文件调整prompt

4.结果样例：

【簇 1】

对话数量: 161

进线原因:

1. 咨询如何购买或申请额外的托运行李额度。
2. 查询特定航班的免费行李额度。
3. 处理行李相关的问题（如额度信息不符、行李遗失）。（数据仅仅是测试数据，随机从原始数据抽取少量实验）

4.案例分析：

1.数据来源:2.22 language为hk并且scenario为改签（11条）和2.23的数据（16条）进行对比。数据量

2.结果分析

Andy Zhang (张宗煜) TR058985 2026年04月07日 15:53

```
================================================================================
模型监控: 2.22 (基准日)  改签场景进线主题分析
================================================================================

【统计概览】
当日样本: 11  |  簇内: 11  |  噪声: 0


【簇 1】
对话数量: 8
id: 100001008259833, 200001007691942, 800001004665172, 300001005538712, 400001005290476, 800001004284813,
400001004222619, 200001008393874
簇的总原因: 机场接送服务因行程变动需修改或退款
进线原因:
1. 因航班延误/取消，要求修改或取消接送服务
2. 需要更改接送服务的具体时间或日期
3. 需要更改接送服务的上车地点
4. 询问修改或取消服务的费用及截止时间
---
--------------------------------------------------------------------------------

【簇 3】
对话数量: 1
id: 200001007654338
簇的总原因: 咨询接送机服务的行李容量与时间更改
进线原因:
1. 询问车辆能装载多少行李
2. 要求更改已预订的接送机服务时间
---
--------------------------------------------------------------------------------

【簇 0】
对话数量: 1
id: 300001007141166
簇的总原因: 用户咨询修改机场接送服务时间
进线原因:
1. 询问修改接送时间后系统是否会显示更新
2. 主动提出需要更改接送机服务的时间
---
--------------------------------------------------------------------------------

【簇 2】
对话数量: 1
id: 500001005939682
簇的总原因: 因病申请机票退改签
进线原因:
1. 申请因病退票
2. 询问因病能否特例更改航班日期
---
--------------------------------------------------------------------------------
```

Andy Zhang (张宗煜) TR058985
2026年04月07日 15:53

5.未来展望及可优化的点：

1.首先我本次的实验调用的api是deepseek的，可以使用好的模型来总结原因，因为分簇是无法干预的从目前的链路来说，所以LLM的优化空间就是原因总结的准不准确。

2.可以在簇和总结原因的LLM层之中加一层用LLM给簇打标签，算是做一个细粒度优化，maybe会提升准确。

3.分簇的方法可以再进一步优化，如果有思路的话。

Andy Zhang (张宗煜) TR058985 2026年04月07日 15:53